


Beyin MR Görüntülerinde Tümör Tespiti

CNN ve Transfer Learning Tabanlı Bir Yaklaşım

DERİN ÖĞRENME DERSİ PROJE ÖDEVİ

HAZIRLAYAN: IŞIL SUIÇMEZ

Giriş



- Beyin MR görüntülerinden tümör tespiti sağlık alanında önemli bir problemidir.
- Bu projede CNN ve transfer learning kullanarak tümörlü ve tümörsüz beyin MR görüntüleri sınıflandırılmıştır.



PROJENİN AMACI

Projede kapsamında;

- Derin öğrenme tabanlı özel bir CNN modeli
- Transfer öğrenme tabanlı ResNet50 ve DenseNet121 mimarileri

kullanılarak, beyin MR görüntülerinde tümör varlığının otomatik olarak tespit edilmesi amaçlanmıştır.

Ayrıca, farklı mimarilerin sınıflandırma performansları karşılaştırılarak en başarılı model belirlenmiştir.




KULLANILAN VERİ SETİ

Kaggle – Brain Tumor MRI Dataset (BR35H)

- Veri seti, beyin MR görüntülerinden oluşmaktadır.
- Görüntüler 2B (2D) MR kesitleri şeklindedir.
- İki sınıf bulunmaktadır:




- 1.Tümörlü
- 2.Tümörsüz







Tümörsüz (No Tumor) MR Görüntüleri

Tümörlü (Tumor) MR Görüntüleri


Tumor Sınıfından Örnekler




No Tumor Sınıfından Örnekler



Veri Setinin Bölünmesi




- Eğitim / Doğrulama / Test
- %70 – %15 – %15
- Sınıf dengesi



Veri Ön İşleme ve Veri Artırma

- Görüntü boyutu: 150×150
- Normalizasyon: 0–1
- Batch boyutu: 32
- Veri artırma:
 1. Döndürme
 2. Kaydırma
 3. Yakınlaştırma
 4. Yatay çevirme

Ön İşleme ve Veri Artırma Sonrası Örnekler



CNN Modelinin Kurulması

Model: "ScratchCNN_Functional"

Layer (type)	Output Shape	Param #
input (InputLayer)	(None, 150, 150, 3)	0
base_conv1 (Conv2D)	(None, 150, 150, 32)	896
pool1 (MaxPooling2D)	(None, 75, 75, 32)	0
base_conv2 (Conv2D)	(None, 75, 75, 64)	18,496
pool2 (MaxPooling2D)	(None, 37, 37, 64)	0
base_conv3 (Conv2D)	(None, 37, 37, 128)	73,856
pool3 (MaxPooling2D)	(None, 18, 18, 128)	0
last_conv (Conv2D)	(None, 18, 18, 128)	147,584
pool4 (MaxPooling2D)	(None, 9, 9, 128)	0
head_gap (GlobalAveragePooling2D)	(None, 128)	0
head_dense (Dense)	(None, 512)	66,048
head_dropout (Dropout)	(None, 512)	0
head_out (Dense)	(None, 1)	513

Total params: 307,393 (1.17 MB)

Trainable params: 307,393 (1.17 MB)



Non-trainable params: 0 (0.00 B)

Modelin Derlenmesi

- Optimizasyon yöntemi olarak Adam kullanılmıştır.
- Kayıp fonksiyonu ikili sınıflandırmaya uygun şekilde binary_crossentropy olarak belirlenmiştir.
- Performans metriği olarak accuracy takip edilmiştir.

```
model.compile(  
    optimizer=Adam(1e-4),  
    loss='binary_crossentropy',  
    metrics=['accuracy'])
```

Model Mimarisi




Eğitim Süreci


- Model 20 epoch boyunca eğitilmiştir.
- EarlyStopping eklenerek model hızlandırılmıştır.
- Eğitim sırasında doğrulama verisi ile performans takip edilmiştir.
- Eğitim ve doğrulama accuracy/loss değerleri grafiklerle izlenmiştir.

```
Epoch 1/20
66/66 ————— 34s 486ms/step - accuracy: 0.4973 - loss: 0.6902 - val_accuracy: 0.5000 - val_loss: 0.6825
Epoch 2/20
66/66 ————— 21s 315ms/step - accuracy: 0.5478 - loss: 0.6798 - val_accuracy: 0.5933 - val_loss: 0.6598
Epoch 3/20
66/66 ————— 21s 324ms/step - accuracy: 0.6100 - loss: 0.6610 - val_accuracy: 0.6911 - val_loss: 0.6239
Epoch 4/20
66/66 ————— 22s 336ms/step - accuracy: 0.5973 - loss: 0.6612 - val_accuracy: 0.7067 - val_loss: 0.6083
Epoch 5/20
66/66 ————— 21s 322ms/step - accuracy: 0.6842 - loss: 0.6114 - val_accuracy: 0.7178 - val_loss: 0.5760
Epoch 6/20
66/66 ————— 22s 328ms/step - accuracy: 0.6883 - loss: 0.6029 - val_accuracy: 0.7133 - val_loss: 0.5675
Epoch 7/20
66/66 ————— 22s 326ms/step - accuracy: 0.6572 - loss: 0.6089 - val_accuracy: 0.7044 - val_loss: 0.5717
Epoch 8/20
66/66 ————— 22s 325ms/step - accuracy: 0.6773 - loss: 0.5878 - val_accuracy: 0.7044 - val_loss: 0.5763
Epoch 9/20
66/66 ————— 22s 331ms/step - accuracy: 0.6895 - loss: 0.5804 - val_accuracy: 0.6867 - val_loss: 0.5836
Epoch 10/20
66/66 ————— 22s 330ms/step - accuracy: 0.6916 - loss: 0.5758 - val_accuracy: 0.6822 - val_loss: 0.5926
Epoch 11/20
66/66 ————— 22s 327ms/step - accuracy: 0.7024 - loss: 0.5793 - val_accuracy: 0.6956 - val_loss: 0.5742
Model başarıyla kaydedildi: best_cnn_br35h.keras
```

Eğitim ve Validation Accuracy Değerleri




Eğitim ve Validation Loss Değerleri




Test Performansı- Örnek Tahminlerin Görselleştirilmesi-Grad-CAM Uygulaması


Gerçek: no
Tahmin: no
Tümör Olasılığı: 34.7%




Gerçek: no
Tahmin: no
Tümör Olasılığı: 27.9%




Gerçek: no
Tahmin: no
Tümör Olasılığı: 19.8%




Gerçek: no
Tahmin: yes
Tümör Olasılığı: 55.5%



Gerçek: no
Tahmin: yes
Tümör Olasılığı: 53.5%



Gerçek: no
Tahmin: no
Tümör Olasılığı: 48.1%




- Eğitim tamamlandıktan sonra model test seti üzerinde değerlendirilmiştir. Rastgele seçilen örnekler üzerinden tahmin yapılarak görselleştirilmiştir.
- Daha sonra bu tahminleri nereye bakarak yaptığını anlamak için Grad-CAM uygulanmıştır.
- Test accuracy ve test loss değerleri raporlanmıştır.

Test Loss : 0.5430

Test Accuracy : 0.7556

Confusion Matrix ve Sınıflandırma Raporu



Classification Report:

	precision	recall	f1-score	support
no	0.76	0.75	0.75	225
yes	0.75	0.76	0.76	225
accuracy			0.76	450
macro avg	0.76	0.76	0.76	450
weighted avg	0.76	0.76	0.76	450

Transfer Learning

- Transfer learning, önceden büyük veri setleri üzerinde eğitilmiş bir derin öğrenme modelinin, yeni ve farklı bir problem için yeniden kullanılmasıdır. Bu yaklaşımda modelin daha önce öğrendiği temel özellikler korunur ve yalnızca probleme özgü katmanlar eğitilir.
- Transfer learning kapsamında ResNet50 ve DenseNet121 modelleri kullanılmıştır. Her iki model de önceden ImageNet veri seti üzerinde eğitilmiş olup, beyin MR görüntü sınıflandırma problemine uyarlanmıştır.



Transfer learning modellerinde sınıflandırıcı başlık (Global Average Pooling + Dense + Dropout) scratch CNN modeli ile aynı tutulmuştur. Böylece karşılaştırma yalnızca feature extractor mimarilerinin etkisine dayanmaktadır.

ResNet50 Modeli

Model: "RESNET50_TL"

Layer (type)	Output Shape	Param #
resnet50_input (InputLayer)	(None, 150, 150, 3)	0
resnet50 (Functional)	(None, 5, 5, 2048)	23,587,712
head_gap (GlobalAveragePooling2D)	(None, 2048)	0
head_dense (Dense)	(None, 512)	1,049,088
head_dropout (Dropout)	(None, 512)	0
head_out (Dense)	(None, 1)	513

Total params: 24,637,313 (93.98 MB)

Trainable params: 1,049,601 (4.00 MB)

Non-trainable params: 23,587,712 (89.98 MB)

DenseNet121 Modeli

Model: "DENSENET121_TL"

Layer (type)	Output Shape	Param #
densenet121_input (InputLayer)	(None, 150, 150, 3)	0
densenet121 (Functional)	(None, 4, 4, 1024)	7,037,504
head_gap (GlobalAveragePooling2D)	(None, 1024)	0
head_dense (Dense)	(None, 512)	524,800
head_dropout (Dropout)	(None, 512)	0
head_out (Dense)	(None, 1)	513

Total params: 7,562,817 (28.85 MB)

Trainable params: 525,313 (2.00 MB)

Non-trainable params: 7,037,504 (26.85 MB)

Modellerin Karşılaştırılması

Scratch CNN


accuracy: 0.7556
precision: 0.7511
recall: 0.7644
f1: 0.7577
auc: 0.8337

ResNet50 TL


accuracy: 0.9356
precision: 0.8920
recall: 0.9911
f1: 0.9389
auc: 0.9924

DenseNet121 TL


accuracy: 0.9689
precision: 0.9689
recall: 0.9689
f1: 0.9689
auc: 0.9947




Scratch CNN Classification Report:				
	precision	recall	f1-score	support
no	0.76	0.75	0.75	225
yes	0.75	0.76	0.76	225
accuracy			0.76	450
macro avg	0.76	0.76	0.76	450
weighted avg	0.76	0.76	0.76	450




ResNet50 TL Classification Report:				
	precision	recall	f1-score	support
no	0.99	0.88	0.93	225
yes	0.89	0.99	0.94	225
accuracy			0.94	450
macro avg	0.94	0.94	0.94	450
weighted avg	0.94	0.94	0.94	450




DenseNet121 TL Classification Report:				
	precision	recall	f1-score	support
no	0.97	0.97	0.97	225
yes	0.97	0.97	0.97	225
accuracy			0.97	450
macro avg	0.97	0.97	0.97	450
weighted avg	0.97	0.97	0.97	450




Grad-CAM ile 3 Model İçin Model Kararlarının Görselleştirilmesi



ResNet50 TL | True: no




Pred: yes (p=0.700)




ResNet50 TL | True: yes




Pred: yes (p=0.925)




ResNet50 TL | True: yes




Pred: yes (p=0.935)




DenseNet121 TL | True: no




Pred: no (p=0.007)




DenseNet121 TL | True: no




Pred: no (p=0.043)



DenseNet121 TL | True: no



Pred: no (p=0.071)




Sonuçlar

- Scratch CNN modeli, temel özellikleri öğrenebilmiş olsa da transfer learning modellerine kıyasla daha düşük performans göstermiştir.

- ResNet50 tabanlı transfer learning yaklaşımı, doğruluk ve F1-score açısından Scratch CNN'e göre belirgin bir iyileşme sağlamıştır.

- DenseNet121 modeli, tüm metrikler (accuracy, precision, recall, F1-score) açısından en yüksek ve en dengeli sonuçları elde etmiştir.

- Elde edilen sonuçlar, önceden eğitilmiş modellerin medikal görüntü sınıflandırmasında önemli avantajlar sunduğunu göstermektedir.



Dinlediğiniz için teşekkürler.